

Algoritmos Memetic Multiobjetivo para o TSP com Janelas de Tempo

Projeto Final INFO415 — Heurísticas e Modelagem Multiobjetivo (UFG, 2026/2) — versão final (Sem 16)

Frederico Barbosa Relvas (202403902)

Cindy Stephanie Gomes Rabelo (202403898)

Davi de Souza Andrade (202403901)

Marcos Vinicius Moreira dos Anjos (202400762)

João Guilherme da Silva Chaveiro (202403908)

Maio de 2026

Resumo

O Problema do Caixeiro Viajante com Janelas de Tempo (TSPTW) é uma extensão do TSP em que cada cidade só pode ser visitada dentro de uma janela $[e_i, l_i]$. A região factível é tipicamente uma pequena fração do espaço de permutações, o que torna a formulação penalizada de um único objetivo sensível ao coeficiente λ escolhido — e propensa a fixar-se em soluções “quase-factíveis”. Este trabalho compara três abordagens sobre cinco instâncias clássicas Dumas com 20 clientes e dez sementes cada: (i) Algoritmo Genético com penalização λ fixa, (ii) NSGA-II tratando distância e violação como objetivos independentes, e (iii) um híbrido memetic NSGA-II + 2-opt Pareto. Em uma busca aleatória com o mesmo orçamento de avaliações do AG, nenhuma das 3 milhões de permutações respeitou simultaneamente todas as janelas, confirmando a estreiteza da região factível. O NSGA-II reproduz os ótimos conhecidos na literatura (378, 254, 335, 237) com factibilidade em 90–100% das sementes em quatro das cinco instâncias, com exceção de `n20w80.001` onde só 2/10 sementes cruzam a viabilidade — gap que motiva a hibridização memetic. O 2-opt Pareto dobra essa fração para 4/10 em `n20w80.001` (e melhora marginalmente outras instâncias), sem custo computacional perceptível. A análise inclui testes pareados de Wilcoxon com correção de Bonferroni, Cliff's δ e g de Hedges como tamanhos de efeito, hypervolume sob ponto de referência unificado, e visualização das fronteiras de Pareto.

1. Introdução

O Problema do Caixeiro Viajante (TSP) é um dos problemas combinatórios mais estudados em pesquisa operacional. Sua variante com janelas de tempo (TSPTW) — introduzida formalmente por Solomon (1987) e estabelecida como benchmark por Dumas et al. (1995) — adiciona a cada cidade i uma janela $[e_i, l_i]$ dentro da qual a visita deve começar. Se o agente chega antes de e_i ,

espera; se chega depois de l_i , ocorre violação. Esse acréscimo aparentemente modesto torna o espaço factível tipicamente uma fração minúscula do espaço de permutações, alinhando o TSPTW com problemas reais de logística onde “tempo importa”: entregas em horário comercial, agendamento médico, rotas escolares.

A literatura aborda o TSPTW por duas grandes vias: heurísticas construtivas seguidas de busca local com vizinhanças sofisticadas — Lin-Kernighan, busca tabu — e algoritmos populacionais que usam penalização para incorporar o aspecto temporal na função objetivo. Cada via tem limitações reconhecidas. As heurísticas construtivas raramente exploram bem o trade-off entre distância e respeito a janelas; os algoritmos populacionais com penalização requerem afinação de um coeficiente λ que mistura grandezas heterogêneas e pode fixar a busca em regiões de “atalho infactível”.

Este trabalho explora a alternativa multiobjetivo: tratar distância e violação total como dois objetivos independentes, gerar uma fronteira de Pareto via NSGA-II (Deb et al. 2002) e — como diferencial principal — hibridizar o NSGA-II com uma busca local 2-opt sob critério de dominância (memetic algorithm). A motivação é direta: experimentos preliminares mostraram que o NSGA-II puro preserva diversidade ao longo da fronteira, mas pode descartar candidatos próximos da viabilidade quando muitos pontos quase-factíveis competem pela mesma região do espaço de objetivos. A busca local 2-opt sobre indivíduos da fronteira atua exatamente nesse gap, perturbando-os até cruzar a fronteira de viabilidade quando isso é alcançável em sua vizinhança.

Contribuições deste trabalho:

1. Reimplementação modular e versionada do TSPTW em Python, com função objetivo penalizada, NSGA-II e hibridização memetic 2-opt Pareto compartilhando os mesmos operadores e dados (Seção 4).
2. Comparação experimental rigorosa entre três métodos (AG penalizado, NSGA-II puro, NSGA-II + 2-opt) sobre cinco instâncias clássicas Dumas com 20 clientes, usando 5 sementes para cada método, testes não-paramétricos de Wilcoxon, Cliff's δ e g de Hedges, e indicador de hypervolume (Seções 5–6).
3. Discussão crítica dos *trade-offs* entre as três formulações, com atenção ao caso `n20w80.001` — onde o NSGA-II puro perde em viabilidade para o AG penalizado e a hibridização memetic é capaz de recuperar a robustez sem renunciar à fronteira de Pareto (Seção 7).

O restante do texto está organizado como segue. A Seção 2 formaliza o TSPTW e introduz a notação utilizada. A Seção 3 contextualiza os trabalhos relacionados. A Seção 4 descreve a metodologia e o desenho experimental. As Seções 5 e 6 apresentam, respectivamente, os resultados quantitativos e a discussão. A Seção 7 conclui e indica trabalhos futuros. O Anexo A traz a contribuição individual da equipe.

2. Formulação do problema

Seja $V = \{0, 1, \dots, n\}$ o conjunto de nós, onde 0 é o depósito e $\{1, \dots, n\}$ são clientes. Para cada arco (i, j) , d_{ij} é a distância (e tempo de viagem, sob a hipótese de velocidade unitária

adotada por Dumas et al. (1995)). Cada cliente $i \in \{1, \dots, n\}$ tem uma janela $[e_i, l_i]$. O tempo de serviço é zero. O depósito tem janela $[0, l_0]$ que delimita o horizonte da rota.

Uma solução é uma permutação $\pi = (\pi_1, \dots, \pi_n)$ dos clientes. A rota completa é $0 \rightarrow \pi_1 \rightarrow \pi_2 \rightarrow \dots \rightarrow \pi_n \rightarrow 0$. Os instantes de chegada t_k em cada posição da rota são determinados de forma recursiva:

$$t_0 = 0, \quad t_k = \max\{t_{k-1} + d_{\pi_{k-1}, \pi_k}, e_{\pi_k}\}, \quad k = 1, \dots, n + 1.$$

A função $\max$ captura a espera permitida (sem violação) se a chegada precede a abertura da janela. A violação ocorre apenas quando $t_k > l_{\pi_k}$, e seu valor é o atraso $t_k - l_{\pi_k}$.

Objetivos. Sejam:

$$f_1(\pi) = \sum_{k=0}^n d_{\pi_k, \pi_{k+1}}, \quad f_2(\pi) = \sum_{k=1}^{n+1} \max\{0, t_k - l_{\pi_k}\}$$

a distância total do tour fechado e a violação total acumulada. O TSPTW clássico (factibilidade-estricta) é o problema de minimizar $f_1(\pi)$ sujeito a $f_2(\pi) = 0$. Adotamos três formulações operacionais:

- **(SO- λ) Single-objective penalizado:** minimizar $f(\pi) = f_1(\pi) + \lambda \cdot f_2(\pi)$, com $\lambda > 0$ fixo. É a formulação clássica usada para tornar tratável a fronteira da região factível.
- **(MO) Multiobjetivo:** minimizar simultaneamente (f_1, f_2) no sentido de Pareto. A solução é uma família $P \subseteq \mathbb{R}^2$ não-dominada, e a interseção com $\{f_2 = 0\}$ recupera os tours factíveis ordenados por distância.
- **(MO+LS) Multiobjetivo memetic:** mesmo objetivo que (MO), mas incorporando busca local sob dominância de Pareto a indivíduos da fronteira atual durante a evolução.

Instâncias. Utilizamos as cinco primeiras instâncias da família Dumas com $n = 20$ clientes, uma por largura média de janela $w \in \{20, 40, 60, 80, 100\}$. As instâncias originais (Dumas et al. 1995) são disponibilizadas como matriz de distâncias inteiras 20×20 acompanhada das janelas de tempo (sem coordenadas euclidianas), distribuídas pelo repositório de López-Ibáñez (2024).

3. Trabalhos relacionados

TSPTW e variantes. A formulação como tratada aqui foi introduzida por Solomon (1987) no contexto do VRP com janelas e estudada como problema autônomo por Dumas et al. (1995), que estabeleceu o conjunto de instâncias usado neste trabalho. Gendreau et al. (1998) propôs uma busca tabu generalizada que ainda é referência. Silva e Urrutia (2010) apresentou uma metaheurística geral baseada em LK + busca tabu que obteve resultados competitivos em todo o benchmark Dumas. Revisões recentes como Cordeau et al. (2002) cobrem a família mais ampla de VRP/TSP com janelas.

Algoritmos populacionais para TSP. O uso de algoritmos genéticos para o TSP padrão está bem estabelecido desde Goldberg e Lingle (1985) e Davis (1985), sendo o último a fonte do Order Crossover (OX) que reusamos aqui. Potvin e Bengio (1996) estende a abordagem para o

VRP com janelas. Gambardella e Dorigo (1996) aplica colônia de formigas a variantes simétricas/assimétricas. Glover (1989) introduz a busca tabu, ainda relevante para o subproblema de busca local.

Otimização multiobjetivo. O algoritmo NSGA-II proposto por Deb et al. (2002) é hoje o método de referência para problemas com 2–3 objetivos por sua combinação de ordenação não-dominada eficiente ($O(MN^2)$) e mecanismo de crowding distance. Zitzler e Thiele (1999) define o indicador de hypervolume usado em nossa análise. Blank e Deb (2020) descreve o framework `pymoo` usado nesta implementação.

Hibridização memetic. Moscato (1989) introduziu o termo *memetic algorithm* para descrever híbridos populacional + busca local. Paquete et al. (2004) aplica a ideia explicitamente a otimização combinatória multiobjetivo (Pareto Local Search). Nossa implementação de 2-opt segue o princípio de dominância de Pareto: um vizinho é aceito apenas se dominar o atual no sentido de Pareto, evitando deteriorar qualquer um dos objetivos.

Análise estatística para metaheurísticas. Seguimos a prática consolidada em García et al. (2010): testes não-paramétricos (Wilcoxon pareado) com tamanho de efeito (Cliff's δ por Romano et al. (2006); g de Hedges com correção de bias por Hedges (1981)).

4. Metodologia

4.1 Componentes compartilhados

Todas as três variantes (SO- λ , MO, MO+LS) compartilham os mesmos componentes base, garantindo comparabilidade:

- **Representação:** permutação dos $n - 1 = 20$ clientes, `numpy.int64`. O depósito é prefixo e sufixo implícitos.
- **Avaliação:** função `evaluate(inst, perm)` que retorna (f_1, f_2) e o vetor de instantes de chegada, em $O(n)$ por chamada (ver Listagem 1).
- **Operador de recombinação:** Order Crossover (OX) de Davis (1985). Dois cortes aleatórios em $\pi^{(1)}$; segmento copiado; restante preenchido com a ordem dos genes em $\pi^{(2)}$ a partir do ponto após o segundo corte, ignorando duplicatas.
- **Operador de mutação:** inversão de subsegmento (2-opt simples), aplicada com probabilidade $p_{mut} = 0,3$.
- **Sementes:** as 10 execuções por instância usam sementes 0–9 (atendendo plenamente o R3 do enunciado). Para o NSGA-II via `pymoo`, a semente é passada a `minimize(seed=)` (ou `algorithm.setup(seed=)` no modo memetic), o que controla `numpy.random` global. Para o AG, a semente é passada a `numpy.random.default_rng(seed)` e propagada explicitamente a todos os operadores.

4.2 SO- λ — Algoritmo Genético penalizado

Implementado em `src/ga.py`. Parâmetros (escolhidos no Checkpoint 1 via *sweep* preliminar): `pop_size = 200`, `n_generations = 1500`, $\lambda = 1000$, seleção por torneio binário ($k = 3$), elitismo top-2. A função de fitness é $f(\pi) = f_1(\pi) + 1000 \cdot f_2(\pi)$. Foi comparado contra dois baselines: (a) **Nearest Neighbor urgency**, uma heurística construtiva que escolhe o próximo cliente minimizando $(1 - \alpha) \cdot t_{\text{chegada}} + \alpha \cdot l_j$ com $\alpha = 0,5$ (penalidade adicional $10^6 \cdot \text{atraso}$); (b) **busca aleatória** com o mesmo orçamento de avaliações (300 000 por semente).

4.3 MO — NSGA-II puro

Implementado em `src/nsga.py` sobre `pymoo 0.6.1` (Blank e Deb 2020). Reusa OX e mutação por inversão da SO- λ , envoltos em `Crossover / Mutation` da `pymoo`. Parâmetros: `pop_size = 100`, `n_generations = 1500`, `p_mut = 0,3`. A redução do `pop_size` em relação ao AG ($200 \rightarrow 100$) compensa o custo $O(N^2)$ por geração da ordenação não-dominada e do *crowding distance*; o número total de avaliações permanece na mesma ordem de grandeza ($\sim 150\,000$).

4.4 MO+LS — NSGA-II memetic com 2-opt Pareto

Implementado em `src/local_search.py` e `src/nsga.py` (função `run_nsga` com `memetic_period > 0`). A cada $M = 100$ gerações, selecionam-se $k = 5$ indivíduos aleatórios da fronteira não-dominada atual. Para cada um aplica-se busca local 2-opt sob critério de dominância:

Para cada par (i, j) com $i < j$, gerar π' invertendo $\pi[i..j]$. Avaliar π' . Se $(f_1(\pi'), f_2(\pi')) \leq (f_1(\pi), f_2(\pi))$ no sentido estrito de Pareto, aceitar $\pi \leftarrow \pi'$ e reiniciar. Iterar até atingir máximo local Pareto ou `max_iter = 5`.

A complexidade por chamada é $O(n^2 \cdot \text{max_iter})$ avaliações; com $n = 20$ isso são até 2000 avaliações por indivíduo, totalizando $5 \cdot 2000 = 10\,000$ avaliações por episódio memetic. Como há $1500/100 = 15$ episódios por execução, o custo extra teórico é $\sim 150\,000$ avaliações por semente — comparável ao orçamento principal do NSGA-II.

4.5 Plano experimental

Cada uma das três variantes é executada 10 vezes (sementes 0–9) sobre as 5 instâncias `n20w{20,40,60,80,100}.001`. Para cada execução são coletados:

- Distância e violação totais da melhor solução final (para SO- λ) ou da fronteira completa (para MO e MO+LS);
- Histórico do melhor fitness (SO- λ) ou hypervolume (MO, MO+LS) por geração;
- Tempo de parede.

Métricas reportadas:

- Para SO- λ : média, desvio padrão, mediana e intervalo de f_1 e f_2 por instância; viabilidade (fração de sementes com $f_2 = 0$); Wilcoxon pareado unilateral com a hipótese $H_1 : f_1^{AG} < f_1^{\text{referência}}$, **correção de Bonferroni** para 5 comparações simultâneas (uma por instância) e tamanhos de efeito (Cliff's δ , Hedges' g). Com 10 sementes, o menor p-valor possível pelo Wilcoxon unilateral é $1/2^{10} \approx 0,001$ — bem abaixo de $\alpha/k = 0,01$ após Bonferroni.
- Para MO e MO+LS: tamanho da fronteira (cardinalidade do conjunto não-dominado), hypervolume com ponto de referência global por instância (máximo observado em todas as sementes e gerações, com margem de 10%), número de soluções factíveis (com $f_2 = 0$) na fronteira final.

Todas as figuras e tabelas são reproduzíveis com três comandos a partir do repositório (cf. Apêndice de reprodutibilidade).

5. Resultados

5.1 SO- λ vs. baselines

A Tabela 1 resume os resultados consolidados com 10 sementes. O AG penalizado supera os dois baselines (NN-urgency e busca aleatória) em distância em todas as 5 instâncias, com Wilcoxon pareado p-valor $\leq 0,023$ contra o NN e $p \leq 0,001$ contra a busca aleatória. Após correção de Bonferroni para 5 comparações ($\alpha/5 = 0,01$), os p-valores contra a busca aleatória permanecem significativos em todas as instâncias; contra o NN, a única que fica marginalmente acima do limiar é `n20w20.001` ($p = 0,023$ vs. $0,01$), refletindo o caso de janelas mais estreitas em que o próprio NN-urgency já é forte. A busca aleatória — 3 milhões de permutações no total (10 sementes $\times$ 5 instâncias $\times$ 300,000 avaliações) — não encontrou nenhuma solução factível.

Os tamanhos de efeito Cliff's δ se mantêm $= -1,000$ (grande, magnitude máxima) em todas as comparações AG vs. Random e em quatro de cinco AG vs. NN. A exceção é `n20w20.001` vs. NN, onde $\delta = -0,600$ (ainda magnitude grande, mas não máxima) porque 2 das 10 sementes do AG produziram distância acima do NN = 386 (395 em uma e 387 em outra). Hedges' g varia entre $-0,79$ (`n20w20.001` vs. NN) e $-30,79$ (`n20w40.001` vs. NN) — todos bem acima do limiar de $|g| = 0,8$ para “grande”.

5.2 MO — NSGA-II puro vs. SO- λ

A Figura 1 mostra as fronteiras de Pareto encontradas pelo NSGA-II puro sobre as cinco instâncias, com os 5 pontos do AG- $\lambda = 1000$ sobrepostos. Em todas as instâncias factíveis, o NSGA-II atinge os mesmos ótimos conhecidos na literatura (378, 254, 335, 237). O resultado mais marcante: em `n20w20.001` (instância mais difícil), o NSGA-II atinge factibilidade em 5/5 sementes, contra apenas 2/5 do AG penalizado.

A Tabela 2 resume os resultados com 10 sementes. Em quatro das cinco instâncias, o NSGA-II atinge o mesmo ótimo factível conhecido (378, 254, 335, 237). A exceção patológica reportada

no Checkpoint 2 — `n20w80.001` — permanece com 10 sementes: o NSGA-II puro atinge viabilidade em apenas 2/10 sementes, enquanto o AG- λ atinge 8/10. Esse é o gap que motiva o diferencial D1 (Seção 5.3).

5.3 MO+LS — Hibridização memetic com 2-opt Pareto

A Tabela 3 compara a versão memetic (NSGA-II + 2-opt, $M = 100$, $k = 5$, $\text{max_iter} = 5$) contra o NSGA-II puro sobre as mesmas 5 instâncias com 10 sementes. **Para garantir uma comparação justa de hypervolume**, recalculamos o HV final de ambos os métodos sob um **ponto de referência unificado** $\rho = \max(F_{\text{puro}} \cup F_{\text{memetic}}) \cdot 1,1 + 1$ — caso contrário, o HV de cada método estaria sob a sua própria caixa de referência (a do memetic, em média menor, porque o 2-opt reduz as violações máximas observadas).

Achados (10 sementes): o operador 2-opt Pareto produz efeito assimétrico entre instâncias. O ganho mais nítido é na **fração de sementes que atingem viabilidade**: em `n20w80.001` (a instância patológica do CP2) ela **dobrou**, de 2/10 para 4/10 sementes, e em `n20w40.001` sobe de 9/10 para 10/10. O ganho de hypervolume é marginal e praticamente nulo em escala unificada (entre $-0,7\%$ e $+1,0\%$). Em `n20w20.001` perde-se uma semente factível ($9/10 \rightarrow 8/10$) — variação ainda plausível em $n = 10$.

Análise por semente em `n20w80.001` (Tabela 4): com o memetic, 4 das 10 sementes (0, 3, 6 e 8) cruzaram a viabilidade — todas haviam ficado próximas (≤ 188 de violação remanescente) na versão pura. Em contrapartida, os 6 seeds que não cruzaram a viabilidade têm `viol_min` maior na versão memetic do que na pura — sinal de que o 2-opt “resolve os mais fáceis” e deixa expostos os casos genuinamente difíceis. O resultado é consistente com a hipótese de que a hibridização atua nos pontos da fronteira a uma distância de busca local da viabilidade.

Custo computacional. O tempo médio por semente do memetic ficou em 98s (5 instâncias), contra 102s do NSGA-II puro — sem custo extra perceptível. A intuição é que o 2-opt agressivo concentra a diversidade da fronteira gradualmente, e isso acelera ligeiramente a ordenação não-dominada interna do `pymoo`. O ganho de tempo é provavelmente acidental; o esperado teórico era 10–20% de custo extra.

6. Discussão

1. **A formulação multiobjetivo expõe o trade-off que λ ocultava.** Com $\lambda = 1000$, fixamos uma “taxa de câmbio” entre violação e distância. A fronteira NSGA-II revela toda a família de soluções não-dominadas, transferindo a decisão para um critério externo (cliente, política, regulação) em vez de pré-cozinhá-la na função objetivo.
2. **MO é mais robusto que SO em janelas estreitas.** O contraste mais nítido com 10 sementes é `n20w20.001`: 3/10 sementes factíveis no AG vs. 9/10 no NSGA-II. O motivo é estrutural: na soma $f_1 + \lambda f_2$, uma solução “374 com violações” tem fitness menor que “378 factível” se λ for insuficiente; no NSGA-II essas duas soluções são mutuamente não-dominadas e ambas são preservadas. Vale notar que em `n20w20.001` o AG é estatisticamente

significativo contra o NN ($p = 0,023$) mas marginal sob Bonferroni — refletindo um caso onde o NN-urgency é forte e o AG só vence em $\sim 7/10$ sementes.

3. **Mas MO pode perder viabilidade onde SO não perderia.** O caso `n20w80.001` confirma com 10 sementes a observação do Checkpoint 2: o NSGA-II puro cai para 2/10 sementes factíveis (vs. 8/10 do AG), evidenciando o efeito colateral do mecanismo de *crowding distance*. Ao priorizar diversidade na fronteira, o NSGA-II descarta candidatos próximos da viabilidade quando há muitos vizinhos quase-factíveis disputando o mesmo nicho. Esse é o gap atacado pela hibridização memetic (Seção 5.3).
4. **MO+LS dobra a viabilidade exatamente onde mais precisa.** Com a estratégia atual (seleção aleatória de 5 indivíduos da fronteira a cada 100 gerações, `max_iter = 5` no 2-opt), o memetic eleva a viabilidade em `n20w80.001` de 2/10 para 4/10 sementes — o ganho que motivara a hibridização. Em `n20w40.001` sobe de 9/10 para 10/10. Em `n20w20.001` há leve recuo (9/10 $\rightarrow$ 8/10), atribuível à variabilidade amostral. O hypervolume sob ponto-ref unificado varia entre $-0,7\%$ e $+1,0\%$ — confirmando que o ganho é principalmente na **forma da fronteira** (mais soluções factíveis presentes) e não em “dominar” a fronteira puro como um todo. A análise por semente em `n20w80.001` (Tabela 4) mostra que o 2-opt resolve os casos “fáceis” (com `viol_min` ≤ 10 na versão puro), enquanto os casos genuinamente difíceis permanecem infactíveis em ambas as versões.
5. **A versão mais focada do D1 é um trabalho futuro claro.** A seleção *aleatória* dos 5 indivíduos da fronteira gasta orçamento em pontos longe da viabilidade. Uma versão dirigida — priorizar indivíduos com f_2 pequeno mas positivo — é candidata óbvia para uma evolução do D1.
6. **O hypervolume tende ao platô em ~ 400 gerações.** A Figura 4 mostra que a maior parte do ganho ocorre nas primeiras 300–400 gerações. Cortar `n_generations` pela metade poderia liberar orçamento para escalar para $n = 40$ ou rodar instâncias adicionais sem aumentar o tempo total.
7. **Ameaças à validade.** (i) Tamanho de instância: $n = 20$ é pequeno para distinguir efeitos sutis; em problemas maiores a hibridização memetic costuma ser ainda mais importante. (ii) Sementes: 10 sementes dão poder estatístico para o Wilcoxon ($p_{\min} \approx 10^{-3}$) mas variabilidade em medidas categóricas como “viabilidade pontual” ainda é alta — diferenças de 1 semente entre 9/10 e 8/10 podem ser ruído. (iii) Seleção de instâncias: usamos apenas a primeira instância de cada largura ($w \in \{20, 40, 60, 80, 100\}$). A entrega completa do conjunto Dumas $n = 20$ tem 25 instâncias; usar todas reduziria viés de instância individual.

7. Conclusões e trabalhos futuros

Apresentamos uma comparação experimental rigorosa entre três formulações para o TSPTW: AG single-objective penalizado, NSGA-II multiobjetivo puro e NSGA-II memetic com busca local 2-opt sob dominância de Pareto. A formulação multiobjetivo dispensa o ajuste de um coeficiente λ e fornece toda a família de soluções não-dominadas; a hibridização memetic preserva essa vantagem enquanto compensa a perda de pressão em direção à viabilidade que afeta o NSGA-II puro em algumas instâncias.

Como trabalhos futuros, quatro direções se destacam: (a) **D1 v2** — substituir a seleção aleatória dos indivíduos para 2-opt por uma seleção dirigida (priorizar pontos com f_2 pequeno e positivo), testando a hipótese de que isso converte o ganho marginal de HV em ganho concreto de viabilidade; (b) **expansão experimental** — incluir as 25 instâncias `n20w*` do conjunto Dumas para reduzir viés de instância individual; (c) **HPO via Optuna** (D3 do enunciado) — afinar `pop_size`, `n_generations` e parâmetros memetic, reportando importância relativa dos hiperparâmetros; (d) **escalabilidade** — repetir o protocolo para `n = 40` e `n = 60`, avaliando se o ganho do memetic cresce com a dimensão. Cabe registrar que (a) e (c) são naturalmente combináveis: HPO pode buscar os parâmetros memetic ótimos (período, k , critério de seleção) em paralelo aos parâmetros do NSGA-II.

Apêndice A — Contribuições da equipe

Conforme a Sec. 8 do enunciado, todos os integrantes participaram da definição do problema, da formulação matemática e da revisão final do relatório. A distribuição operacional por componente foi a seguinte:

- **Frederico Barbosa Relvas:** coordenação do diferencial D1 (busca local 2-opt sob dominância de Pareto), execução dos experimentos com 10 sementes, validação dos resultados contra o ótimo conhecido em literatura, e redação das Seções 4.4 e 6.
- **Cindy Stephanie Gomes Rabelo:** baseline Nearest Neighbor com critério `urgency`, busca aleatória como referência inferior, análise estatística (Wilcoxon, Cliff's δ , Hedges' g) e tabelas da Seção 5.
- **Davi de Souza Andrade:** estrutura do repositório Python, módulo `instance.py` (loader Dumas), módulo `evaluation.py` (função objetivo TSPTW), pipeline reprodutível (experiment runners), versionamento via Git tags por checkpoint, e redação das Seções 1, 2 e 7.
- **Marcos Vinicius Moreira dos Anjos:** implementação do Algoritmo Genético em `src/ga.py` (OX, mutação por inversão, torneio, elitismo), *sweep* de λ no Checkpoint 1 e plano experimental do Checkpoint 1. Redação da Seção 3 e revisão geral.
- **João Guilherme da Silva Chaveiro:** integração com `pymoo` (NSGA-II em `src/nsga.py`), cálculo de hypervolume com ponto-ref unificado, scripts de figuras (`notebooks/*_figures.py`), e validação visual de todas as figuras produzidas.

Avaliação majoritariamente conjunta. Disputas técnicas foram resolvidas via discussão por canal próprio da equipe e registradas no histórico de *commits* do repositório.

Apêndice B — Reprodutibilidade

Código e dados públicos em https://github.com/DavideSouzaAndrade/heuristica_proj. Para reproduzir os resultados:

```
git checkout final
pip install -r requirements.txt
python -m src.experiment --instance cp1 --seeds 10 --tag final      # SO-λ
python -m src.experiment_moo --instance cp1 --seeds 10 --tag final # MO puro
python -m src.experiment_moo --instance cp1 --seeds 10 \
    --memetic-period 100 --tag final --suffix _memetic             # MO+LS
python notebooks/final_figures.py
```

O script `notebooks/final_figures.py` gera as figuras 1–8 do relatório a partir dos artefatos em `entregas/final/resultados/`. Tempo total estimado em máquina típica de desenvolvimento: aproximadamente 3h30min para os três experimentos sequenciais.

Declaração de uso de IA generativa

Conforme política da disciplina (Sec. 11 do enunciado), declaramos: Claude Code (Anthropic) atuou como assistente de programação ao longo do projeto — estruturação do esqueleto Python, escrita de boilerplate (loaders, runners de experimentos, geração de figuras), debugging interativo e revisão de redação. Decisões metodológicas (escolha do problema, da formulação, dos algoritmos, dos hiperparâmetros, do diferencial), interpretação dos resultados e elaboração das conclusões são da equipe. Toda referência citada foi verificada manualmente.

Referências

(usar Pandoc com `--citeproc` e arquivo `.bib` na build do PDF; a lista abaixo lista as principais)

(Solomon 1987; Dumas et al. 1995; Gendreau et al. 1998; Silva e Urrutia 2010; Cordeau et al. 2002; Goldberg e Lingle 1985; Davis 1985; Potvin e Bengio 1996; Gambardella e Dorigo 1996; Glover 1989; Deb et al. 2002; Zitzler e Thiele 1999; Blank e Deb 2020; Moscato 1989; Paquete et al. 2004; García et al. 2010; Romano et al. 2006; Hedges 1981; López-Ibáñez 2024)

Blank, Julian, e Kalyanmoy Deb. 2020. “pymoo: Multi-Objective Optimization in Python”. *IEEE Access* 8: 89497–509.

Cordeau, Jean-François, Michel Gendreau, Gilbert Laporte, Jean-Yves Potvin, e Frédéric Semet. 2002. “A Guide to Vehicle Routing Heuristics”. *Journal of the Operational Research Society* 53 (5): 512–22.

Davis, Lawrence. 1985. “Applying Adaptive Algorithms to Epistatic Domains”. *IJCAI*, 162–64.

Deb, Kalyanmoy, Amrit Pratap, Sameer Agarwal, e T. Meyarivan. 2002. “A Fast and Elitist Multiobjective Genetic Algorithm: NSGA-II”. *IEEE Transactions on Evolutionary Computation* 6 (2): 182–97.

Dumas, Yvan, Jacques Desrosiers, Éric Gélinas, e Marius M. Solomon. 1995. “An Optimal Algorithm for the Traveling Salesman Problem with Time Windows”. *Operations Research* 43 (2): 367–71.

Gambardella, Luca Maria, e Marco Dorigo. 1996. “Solving Symmetric and Asymmetric TSPs by Ant Colonies”. *Proceedings of IEEE International Conference on Evolutionary Computation*, 622–27.

- García, Salvador, Alberto Fernández, Julián Luengo, e Francisco Herrera. 2010. “Advanced Nonparametric Tests for Multiple Comparisons in the Design of Experiments in Computational Intelligence and Data Mining: Experimental Analysis of Power”. *Information Sciences* 180 (10): 2044–64.
- Gendreau, Michel, Alain Hertz, Gilbert Laporte, e Mihnea Stan. 1998. “A Generalized Insertion Heuristic for the Traveling Salesman Problem with Time Windows”. *Operations Research* 46 (3): 330–35.
- Glover, Fred. 1989. “Tabu Search — Part I”. *ORSA Journal on Computing* 1 (3): 190–206.
- Goldberg, David E., e Robert Lingle. 1985. “Alleles, Loci, and the Traveling Salesman Problem”. *Proceedings of the International Conference on Genetic Algorithms*, 154–59.
- Hedges, Larry V. 1981. “Distribution Theory for Glass’s Estimator of Effect Size and Related Estimators”. *Journal of Educational Statistics* 6 (2): 107–28.
- López-Ibáñez, Manuel. 2024. *TSPTW Instances*. <https://lopez-ibanez.eu/tsptw-instances>.
- Moscato, Pablo. 1989. *On Evolution, Search, Optimization, Genetic Algorithms and Martial Arts: Towards Memetic Algorithms*. Caltech Concurrent Computation Program, Report 826.
- Paquete, Luís, Marco Chiarandini, e Thomas Stützle. 2004. “Pareto Local Optimum Sets in the Biobjective Traveling Salesman Problem: An Experimental Study”. *Metaheuristics for Multiobjective Optimisation*, 177–99.
- Potvin, Jean-Yves, e Samy Bengio. 1996. “The Vehicle Routing Problem with Time Windows — Part II: Genetic Search”. *INFORMS Journal on Computing* 8 (2): 165–72.
- Romano, Jeanine, Jeffrey D. Kromrey, Jesse Coraggio, e Jeff Skowronek. 2006. “Appropriate Statistics for Ordinal Level Data: Should We Really Be Using t-Test and Cohen’s d for Evaluating Group Differences on the NSSE and Other Surveys?” *Annual Meeting of the Florida Association of Institutional Research*, 1–33.
- Silva, Rodrigo Ferreira da, e Sebastián Urrutia. 2010. “A General VNS Heuristic for the Traveling Salesman Problem with Time Windows”. *Discrete Optimization* 7 (4): 203–11.
- Solomon, Marius M. 1987. “Algorithms for the Vehicle Routing and Scheduling Problems with Time Window Constraints”. *Operations Research* 35 (2): 254–65.
- Zitzler, Eckart, e Lothar Thiele. 1999. “Multiobjective Evolutionary Algorithms: A Comparative Case Study and the Strength Pareto Approach”. *IEEE Transactions on Evolutionary Computation* 3 (4): 257–71.